Q-Loop

매출 결과로 문항을 고르고 고치는 설문 에이전트

설문이 보고서로 끝나 매출 액션과 끊겨 있으면, 어떤 문항이 실제로 매출을 움직였는지 아무도 모른 채 문항만 쌓인다. Q-Loop 는 문항마다 **"누구에게 어떤 액션을 줄지 바꾸는가"**를 따져 남길지 정한다. 액션의 실제 매출 결과가 다음 분기 설문을 바꾼다.

26.5%

문항 고정 23.5% · 기존 3.8%

8분기 순이익 포착률(정답을 알 때의 최선 대비). Q-Loop vs 같은 학습기·문항 고정. 시드 20개 중 20개 우위 · 심은 정답 시뮬레이션

14→7문항

시험 AUC 0.925 → 0.924

실제 응답 129,880건(공개 항공 만족도 설문) 출장 고객 세그먼트. 개인 고객은 14→4문항, AUC -0.001

0 / 69

실제 OpenAI 모델이 지어낸 숫자

Codex CLI 로 받은 플랜 문장 69개를 표와 대조. 이 출력으로 검증기가 맞는 문장을 막던 결함을 찾아 고쳤다(v2)

무엇이 다른가

- **상관이 아니라 효과로 문항을 고른다.** 만족도-매출 상관은 '누가 많이 사나'를 알려줄 뿐이다. Q-Loop 는 고객 15%에 액션을 무작위 배정하고, 응답에 따라 액션 효과가 갈리는 정도(액션×문항 상호작용의 |t|)를 문항의 결정 기여도로 쓴다.
- **거래조건은 추첨하지 않는다.** B2B 는 방문 교육·샘플 측정·재고보충 제안 같은 서비스성 액션만 추첨한다. 근거 문항은 |t|≥3 일 때만 영업 화면에 보여 준다.
- **문항이 진화한다.** 기여 없는 문항은 부활 조건과 함께 폐기, 개방형 응답에서 떠오른 주제는 새 문항으로 시험·승격. 근거 2회 전에는 바꾸지 않고, 회차당 변경 2개, 성과가 떨어지면 되돌린다.
- **LLM 은 숫자를 만들지 않는다.** 숫자는 코드가 계산하고 문장은 인용만 한다. 검증기가 표에서 다시 계산해 틀린 문장을 막는다. 설문 발송·플랜 배포는 담당자 승인.

한국후지필름에서는

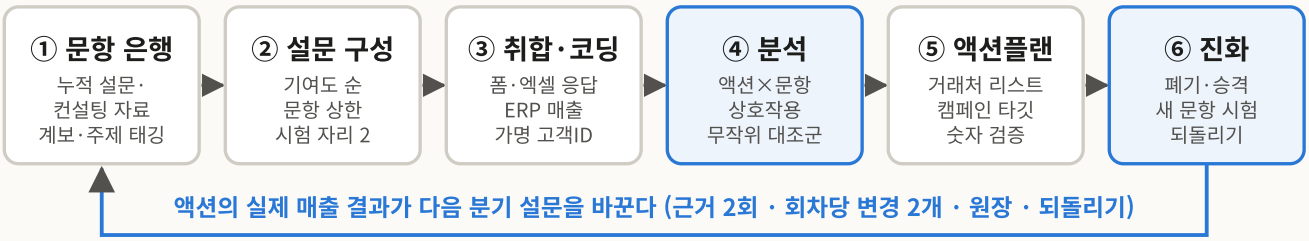
세그먼트	개방형 응답에서 떠오른 신호 → 새 문항	연결 액션
사진관·인화점 파트너	"인화지가 자주 떨어져요" → 결품 빈도	자동 재고보충 계약
산업재(LTO·프리스케일)	"납기가 들쭉날쭉해요" → 납기 지연 경험	납기 보장 옵션
인스탁스·후지필름몰 회원	"필름값이 부담" / "포토카드 만들고 싶어요"	필름 구독 할인 / 사진상점F·야구장 포토카드 연계 번들

재현: github.com/Taewoo-Won/lotte-ax-qloop — 사전등록(docs/PREREG.md), 실험 4종(실제 OpenAI 모델 출력 포함), 결과 JSON, 시험. 본 문서의 모든 수치는 results/ 파일에서 자동으로 읽어 넣었다.

구조

분기마다 도는 6단계 — 결과가 다음 설문을 바꾼다

사람 승인: ② 설문 발송 전 · ⑤ 액션플랜 배포 전



역할 분담

누가	무엇을
LLM	누적 문서 해석, 개방형 응답 코딩, 새 문항 문구, 플랜 문장(숫자는 인용만)
코드	결정 기여도, 효과 추정, 고객별 배정, 폐기·승격·되돌리기, 문장 검증
사람	설문 발송 승인, 액션플랜 배포 승인, 불변 규칙 변경

불변 영역 — 진화기가 못 건드림

- 추세 비교용 앵커 문항(전반 만족)
- 추첨 대조군 하한 10% (기본 15%) — 코드에서 강제
- 숫자 검증기 — 코드에서 강제
- 고객 ID 가명 처리 · 개인정보 LLM 비전송 — 본선 어댑터에서 구현

에이전트 코드가 시뮬레이션 정답 모듈을 import 하지 못하게 시험으로 막았다(tests/test_core.py).

OpenAI 스택(2026-11 기준)

구성	선택
오케스트레이션	Agents SDK 0.24.0 · Responses API · Structured Outputs
사람 승인	`needs_approval=True` (발송·배포 도구)
숫자 보증	출력 가드레일 = 검증기(하나라도 틀리면 차단)
평가	자체 하네스 — Agent Builder 는 11-30 종료, 호스티드 Evals 는 10-31 읽기 전용·11-30 종료라 미사용

배선은 키 없이 구성과 가드레일 차단까지 시험했다. 실제 모델 출력 시험은 서버의 Codex CLI(구독, 기본 모델 gpt-5.6-sol)로 했다 — 5쪽.

모델 배분 — 오류가 번지는가, 되돌릴 수 있는가

단계	모델	이유
개방형 1차 분류	gpt-6-luna	대량·되돌릴 수 있음 (Decisions API 사용 가능 시 선택형). 사람 분류 200건과 κ 비교, 선행연구 zero-shot κ 0.76(GPT-4o, 독일어 설문 5,072건) 미달 시 상향
불일치 판정·문항·플랜 문장	gpt-6.1-sol	고객에게 나가거나 경영 판단에 쓰임
스캔본·표 이미지	gpt-6.1-terra	시각 입력
기여도·배정·폐기	코드	재현·감사 가능해야 함

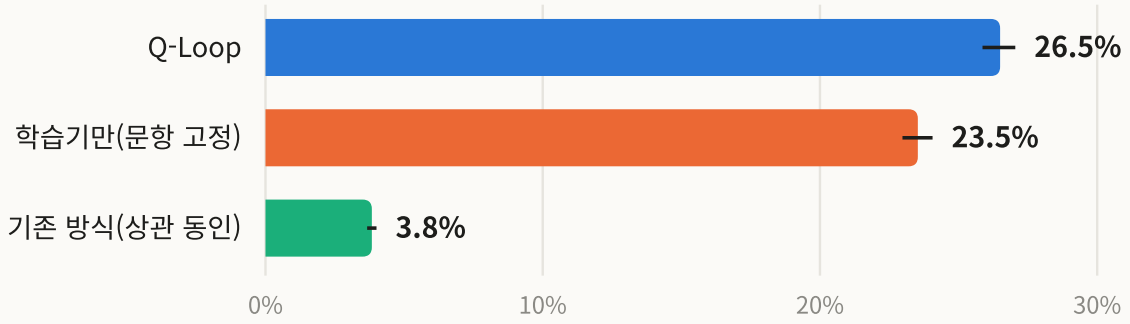
합성 응답자는 의사결정에 쓰지 않는다 — LLM 실리콘 샘플링이 응답을 동질화한다는 연구 결과(Li 외, arXiv 2507.02919) 때문.

실증 1 · 심은 정답 시뮬레이션 (비교 실행 전 설계 고정)

문항이 진화하면 액션이 맞는 고객에게 간다

후지필름형 세그먼트 3개(파트너 400곳 · 산업재 160곳 · 회원 4,000명), 8분기, 시드 20개. 누적 문항이 재지 못하는 니즈(결품·납기·필름값)와 5번째 분기에 새로 생기는 굿즈 수요를 심었다. 세 정책을 공통 난수로 같은 세계에 나란히 돌렸다.

8분기 누적 순이익 — 정답을 알 때의 최선 대비 포착률 (선: 시드 부트스트랩 95% 구간)



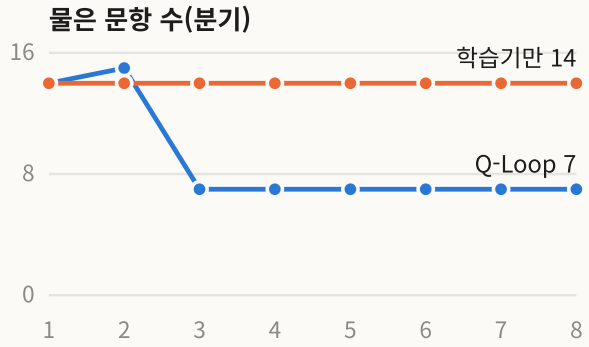
세그먼트	Q-Loop	학습기만	기존 방식
사진관·인화점 파트너	13.7%	8.1%	1.2%
산업재(LTO·프리스케일)	17.7%	16.1%	11.0%
인스탁스·몰 회원	27.4%	24.5%	3.8%

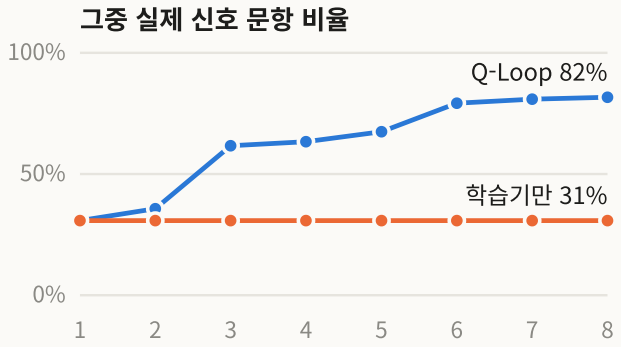
짝 차이 Q-Loop − 학습기만 +3.0%p [2.6, 3.3], 20/20 시드 우위. 응답률이 설문 길이에 안 떨어지는 세계에서도 +2.8%p — 우위가 짧은 설문의 응답률 효과만은 아니다. 세그먼트별 우위 시드: 사진관 19/20 · 산업재 13/20 · 회원 20/20. B2B 거래조건 추첨 금지 버전(사후 추가) +2.7%p, 20/20.

진화 판단의 정오(세계 정답으로 채점)	승격 중 실제 신호	폐기 중 실제 신호
사진관·인화점 파트너	19/26	11/40
산업재(LTO·프리스케일)	8/14	24/80
인스탁스·몰 회원	38/40	2/17

B2C 처럼 응답이 많으면 승격이 정확하다(승격 40건 중 재시험 복귀 2건을 뺀 새 문항 38건이 모두 신호). B2B 두 세그먼트는 폐기 판단의 28~30%가 실제 신호 문항 — 계층 모델·담당자 승인으로 보완.

B2C 회원 세그먼트 — 설문은 짧아지고 신호는 진해진다

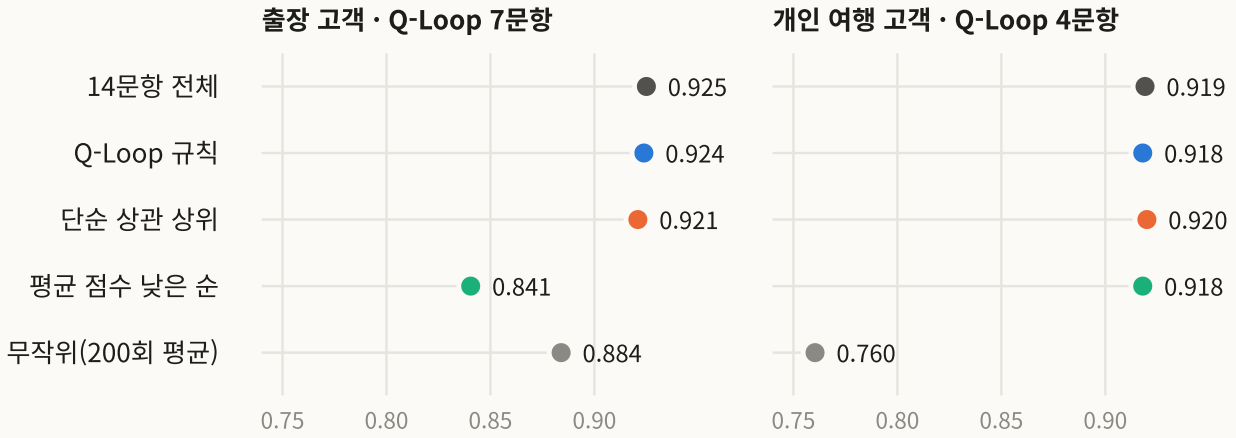




누적 문항이 못 재던 니즈는 모든 시드에서 2분기에 새 문항으로 잡혔고(산업재 납기 문항은 이후 25% 시드에서 다시 빠짐), 5번째 분기에 생긴 굿즈 수요는 그다음 분기에 잡혔다. 되돌리기는 60개 세그먼트-실행 중 5회 발동. **한계:** 이 세계는 직접 만든 것이라 결과는 "메커니즘이 설계대로 작동한다"는 증거이지 실제 매출 효과의 크기가 아니다. 기존 방식의 낮은 성적은 '만족도가 매출 수준과만 엮인다'는 세계 가정에서 나온다.

실제 사람 응답에서도 정보를 잃지 않고 줄었다

공개 항공 만족도 설문(학습 103,904명 · 시험 25,976명, 서비스 평가 14문항 + 만족 여부)을 출장 고객과 개인 여행 고객으로 나눠, 응답을 6개 물결로 흘리며 같은 절차(2회 연속 미달 폐기 · 중복 정리 · 상한)를 예측 기여도로 적용했다. 시험 데이터는 마지막에 한 번만 썼고, 비교 방식에는 Q-Loop 가 스스로 정한 문항 수를 그대로 줬다.



남은 문항 — 출장: 온라인 탑승수속 · 탑승 서비스 · 체크인 서비스 · 기내 엔터테인먼트 · 기내 와이파이 · 다리 공간 · 게이트 위치 / 개인: 기내 와이파이 · 온라인 예약 편의 · 게이트 위치 · 온라인 탑승수속

정직하게 읽기. 결과 예측만 보면 단순 상관 상위 선택도 비슷했다(출장 0.921, 개인 0.920). 개인 고객에서는 '평균 점수 낮은 순'도 같은 문항을 골랐다. Q-Loop 의 차별점은 예측이 아니라 **액션 효과를 가르는 데** 있고, 그건 실증 1이 보여 준다. 이 실험이 보여 주는 것은 폐기 절차가 실제 응답에서 정보를 잃지 않는다는 점과, 고객군마다 남는 문항이 다르다는 점이다.

근거 문항 — 뚜렷할 때만 보여 준다(사후 추가)

세그먼트(시드 20, 마지막 분기)	최댓값 문항을 그대로 쓸 때	|t|≥3 만 표시
사진관·인화점 파트너	26/80	7/7
산업재(LTO·프리스케일)	19/60	3/4
인스탁스·몰 회원	84/100	70/71

'실제 니즈 문항'은 세계 정답으로 채점. 기준 미만이면 영업 화면에 "근거 문항 없음 — 평균 효과로 배정"으로 쓴다.

실제 모델은 숫자를 지어내지 않았고, 틀린 건 검증기였다

에이전트가 쓰는 숫자표(인용 키 → 값)를 그대로 주고, 모델에게 액션플랜 문장과 인용 키를 쓰게 했다. 문장마다 검증기로 채점하고, 별도로 표와 직접 대조해 숫자를 지어낸 문장이 있는지 셌다.

출력 묶음	문장	검증기 v1 통과	v2 통과	숫자 지어냄(표 대조)
시드 0 — v2 를 고칠 때 본 출력	24	15	**24**	0
시드 3 — v2 가 안 본 새 출력	24	14	**23**	0
시드 7 — v2 가 안 본 새 출력	21	14	**16**	0

v1 이 막은 9개 — 전부 맞는 문장

v1 은 "인용한 숫자가 문장에 그대로 있어야 한다"는 한 가지 문장 유형만 알았다. 실제 모델은 다른 유형으로 썼다.

- **근거 없음 8개** — 「자동 재고보충 계약은 근거 문항 없음 — 평균 효과로 배정.」 t값(기준 3 미만)을 근거로 인용하고 숫자는 안 씀
- **순위 주장 1개** — 「실행 우선순위는 평균 효과가 가장 높은 필름 구독 할인을 중심으로 두고, 포토카드 굿즈 번들과 선물 패키지 …」

v2 가 안 본 출력: 45문장 중 39개 통과. 막힌 6개도 모두 맞는 문장이었다(순위어 없는 우선순위 1 · '근거 없음'에 쓰지 않은 평균 효과까지 인용 3 · t값 인용 없이 '근거 없음' 2). 지금은 막히면 배포 전체를 멈추고, 본선에서는 막힌 문장만 담당자 확인으로 넘긴다.

v2: 문장 유형별로 판정한다. 근거 없음 → 인용한 t값이 실제로 3 미만인가, 순위 → 그 액션이 실제 최댓값인가. 원본 검증기(qloop/verifier.py)를 고쳤고 Agents SDK 출력 가드레일도 같은 함수를 쓴다.

공격 시험 — v2 로 다시

틀리게 바꾼 방식	차단/생성
숫자 크기 변경	306/306
부호 뒤집기	156/156
자릿수 바꾸기	307/307
근거 문항 바꿔치기	37/37
인용 없는 숫자 끼워 넣기	390/390
근거가 뚜렷한데 '없음'이라고 쓰기(v2)	37/37
최댓값 아닌 액션을 '가장 높다'고 쓰기(v2)	90/90
합계 · 맞는 문장 통과 420/420	**1323/1323**

개방형 응답 분류 — 실제 모델 82/87 · 사전 코더 75/87 · 시드 3 재실행 84/87 · 시드 7 재실행 82/87

모델이 정답과 다르게 분류한 응답	시뮬레이션 정답	모델
「주문 넣으면 일주일 넘게 걸려요」	재고·결품	납기
「급하게 필요할 때 받을 방법이 없어요」	재고·결품	배송
「앱이 조금 느려요」	없음	앱·온라인몰
「매장 직원분이 친절했어요」	없음	서비스·AS
「배송이 조금 늦었어요」	없음	배송

정직하게 읽기. 불일치 중 여럿은 정답 쪽이 애매하다(시뮬레이션이 '무관한 말'로 넣은 문장이 목록의 주제와 겹침). 응답 문장은 직접 만든 것이라 실제 고객 응답의 분류 정확도는 본선에서 사람 표본 κ 로 잰다. **검증기가 못 잡는 것:** 숫자에 붙인 이름 — 모델은 t값을 '효과 지표'라고 불렀다. 숫자는 맞아 통과했고, 이런 의미 오류는 사람 검토 몫으로 남긴다.

본선 계획

당일 공개 데이터로 1박 2일 안에 고리를 닫는다

시간	할 일	끝났다는 기준
0~2h	데이터 구조 파악, 입력 어댑터 3종(누적 설문 · 응답 · 매출) 매핑. 매출이 없으면 재구매·문의를 대리 결과로	표준 응답표·결과표가 가명 ID로 결합
2~6h	누적 자료 → 문항 은행 적재(계보·주제), 첫 회차 분석	문항별 결정 기여도 표
6~12h	액션플랜 + 검증 가드레일 + 승인 흐름 연결	틀린 숫자 문장 차단을 현장 데이터로 시연
12~18h	현장 과거 회차를 순서대로 다시 돌리는 백테스트로 진화 규칙 효과 측정	문항 수·포착률을 현장 데이터에서 실측
18~24h	담당자 화면(거래처 방문 리스트 · 캠페인 타깃 · 바뀌는 문항과 이유)과 발표	측정한 숫자만 발표

사전 작성 코드 사용 가능 여부는 미확인. 허용되면 저장소를 그대로, 불허면 설계·규칙·시험 케이스만 가져가 핵심부(분석·진화·검증)를 다시 구현한다.

성과 지표

- 설문 문항 수 · 응답률
- 무작위 대조군 대비 액션 순이익
- 개방형 코딩 κ(사람 표본 대비)
- 검증기 차단율 · 되돌리기 횟수

확산

구조는 '설문 + 매출'이 있는 어느 계열사에나 그대로 쓰인다. 어댑터만 바꾸면 칠성·웰푸드의 소비자 조사, 홈쇼핑의 방송 후 설문에도 붙는다. 롯데이노베이트 아이멤버의 에이전트로 넣으면 그룹 공통 도구가 된다.

알려진 약점 → 보완

- 작은 B2B 세그먼트는 검정력 부족(오폐기 약 30%) → 세그먼트 간 정보를 빌리는 계층 모델
- 액션 여러 개 중 최대 |t| 라 우연히 큰 값 → 순열 귀무분포로 임계값 보정
- 오프라인 코더는 시뮬 문장과 같은 손에서 나와 정확도가 과대평가 → 본선은 LLM 코딩 + 사람 표본 κ

예시 — 시드 0 회원 세그먼트의 진화 원장(실행 기록 그대로)

시점	변경	문항	근거
1분기	새 문항 후보	「필름 가격 때문에 촬영을 줄인 적이 있다」	개방형 응답에서 '필름가격' 가 14% — 이를 재는 문항이 없음
2분기	폐기	「후지필름몰 앱이 편리하다」	최근 2회 결정 기여도 |t|<1.0
2분기	폐기	「오프라인 매장을 자주 방문한다」	최근 2회 결정 기여도 |t|<1.0
3분기	승격	「필름 가격 때문에 촬영을 줄인 적이 있다」	새 문항 시험 통과 — 결정 기여도 연속 |t|≥2.0
5분기	새 문항 후보	「사진으로 포토카드·굿즈를 만들어 보고 싶다」	개방형 응답에서 '굿즈·포토카드' 가 12% — 이를 재는 문항이 없음
8분기	승격	「사진으로 포토카드·굿즈를 만들어 보고 싶다」	새 문항 시험 통과 — 결정 기여도 연속 |t|≥2.0

스스로 검증하고 고치며 도는 루프를 만들어 왔다

클라우드 서버(Ubuntu)에 Claude Code(헤드리스)와 OpenAI Codex CLI 를 함께 두고 cron·systemd 로 묶어, 사람이 매번 지시하지 않아도 도는 에이전트 루프를 설계·운영해 왔다. Q-Loop 의 규칙들은 이 경험에서 나왔다.

자율 연구 루프 2026.09~10 · 159라운드 무인 운영

시장 데이터에서 반복 가능한 규칙을 찾는 연구를 에이전트에 맡겼다. 매 라운드 프롬프트 앞에 불변 규칙 · 폐기된 가설 목록(부활 조건 필수) · 남은 산출물 목록을 붙여 기억에 기대지 않게 했고, 감사·실행·제안·탐색 네 모드로 나눠 새 방향 탐색만 사람 승인을 받게 했다. 사전등록과 홀드아웃 분리를 지켰다. 결론은 "검증된 규칙 0건" — 그럴듯한 결과를 지어내지 않는 루프가 Q-Loop '근거 2회 전에는 안 바꾼다'의 출발점이다.

일감 자동 수주 엔진 2026.08 · 독립 채점 에이전트 · 자기 정제

프리랜서 플랫폼 일감 탐지 → 자동화 가능 판정 → 산출물 선제작 → 쓰기 권한 없는 채점 에이전트의 검수 → 입찰 → 결과 추적 → 규칙 자기 정제. 정제기는 불변/가변 영역을 나누고, 같은 근거가 3번 반복돼야 바꾸며, 회차당 2개만 바꾸고, 모든 변경을 원장·스냅샷으로 되돌릴 수 있게 했다. 첫 실전 입찰 10명 중 9위 뒤 "입찰자는 먼저 연락할 수 없다"는 구조적 원인을 찾아 전략을 바꿨다.

사고 구조 복원 엔진 2026.09 · 비정형 → 의사결정 필드

공개 SNS 글을 수집해 '무엇을 보고 · 어떤 사건에 반응하고 · 무엇을 따지고 · 어떤 가설 · 무엇으로 확인하는가'로 구조화했다. 개방형 응답 코딩과 같은 문제다. 학습·검증 데이터를 물리적으로 분리해 검증 데이터를 한 모델이 아예 못 읽게 했다.

공공데이터 공모전 응모 파이프라인 2026.10~ · 수집 · 문서 생성 · 블라인드 심사

공식 통계 API 수집기(키를 로그·출력에서 가림), HWP/HWPX 문서 생성과 렌더링 검수, 블라인드 AI 심사와 원출처 대조를 묶어 여러 대회 응모작을 만들었다.

일하는 원칙 — 실패에서 나온 것

측정과 판정을 분리한다 · 불확실한 응답을 성공으로 읽지 않는다 · 모든 상수에 도출 근거, 없으면 지운다 · 문서의 안전장치가 코드에 실제로 있는지 확인한다 · 합계가 맞아도 구간별로 다시 맞춘다.

이 응모작도 같은 방식으로 만들었다: 지원자가 목표와 검증 원칙(실측 숫자만 · 비교 전 사전등록 · 정답 모듈 격리)을 정하고, AI 에이전트가 과제 분석·구현·실험·문안 초안을 맡고, 지원자가 검토해 제출한다.