Q-Loop

문항이 매출로 검증받고, 스스로 날카로워지는 설문 에이전트

설문이 보고서로 끝나 매출 액션과 끊겨 있으면, 어떤 문항이 실제로 매출을 움직였는지 아무도 모른 채 문항만 쌓인다. Q-Loop 는 모든 문항에게 **"누구에게 어떤 액션을 줄지 바꾸는가"**로 자리를 증명하게 한다. 액션의 실제 매출 결과가 다음 분기 설문을 바꾸는 닫힌 고리다.

26.5%

문항 고정 23.5% · 기존 3.8%

8분기 순이익 포착률(정답을 알 때의 최선 대비). Q-Loop vs 같은 학습기·문항 고정. 시드 20개 중 20개 우위 · 심은 정답 시뮬레이션

14→7문항

시험 AUC 0.925 → 0.924

실제 응답 129,880건(공개 항공 만족도 설문) 출장 고객 세그먼트. 개인 고객은 14→4문항, AUC -0.001

1,528 / 1,528

틀린 숫자 문장 차단

틀리게 바꾼 리포트 문장 차단(맞는 문장 390/390 통과). 생성기·검증기를 같은 사람이 만든 기계적 보증 시험

무엇이 다른가

- **상관이 아니라 효과로 문항을 고른다.** 만족도-매출 상관은 '누가 많이 사나'를 알려줄 뿐이다. Q-Loop 는 고객 15%에 액션을 무작위 배정하고, 응답에 따라 액션 효과가 갈리는 정도(액션×문항 상호작용의 |t|)를 문항의 결정 기여도로 쓴다.
- **문항이 진화한다.** 기여 없는 문항은 부활 조건과 함께 폐기, 개방형 응답에서 떠오른 주제는 새 문항으로 시험·승격. 근거 2회 전에는 바꾸지 않고, 회차당 변경 2개, 성과가 떨어지면 되돌린다.
- **LLM 은 숫자를 만들지 않는다.** 숫자는 코드가 계산하고 문장은 인용만 한다. 검증기가 표에서 다시 계산해 틀린 문장을 막는다. 설문 발송·플랜 배포는 담당자 승인.

한국후지필름에서는

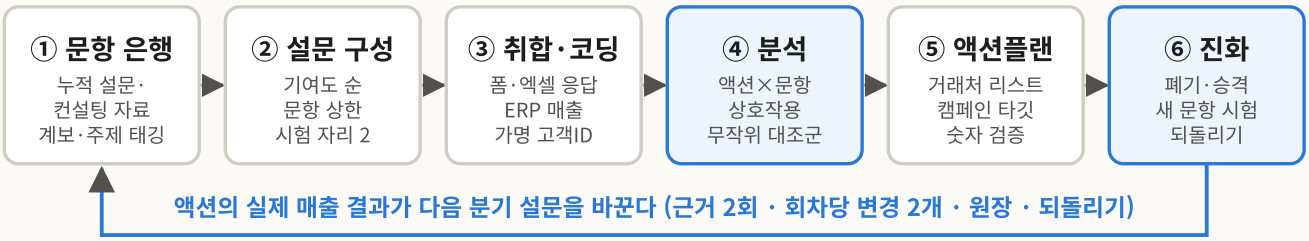
세그먼트	개방형 응답에서 떠오른 신호 → 새 문항	연결 액션
사진관·인화점 파트너	"인화지가 자주 떨어져요" → 결품 빈도	자동 재고보충 계약
산업재(LTO·프리스케일)	"납기가 들쭉날쭉해요" → 납기 지연 경험	납기 보장 옵션
인스탁스·후지필름몰 회원	"필름값이 부담" / "포토카드 만들고 싶어요"	필름 구독 할인 / 사진상점F·야구장 포토카드 연계 번들

재현: github.com/Taewoo-Won/lotte-ax-qloop — 사전등록(docs/PREREG.md), 실험 3종, 결과 JSON, 시험. 본 문서의 모든 수치는 results/ 파일에서 자동으로 읽어 넣었다.

구조

분기마다 도는 6단계 닫힌 고리

사람 승인: ② 설문 발송 전 · ⑤ 액션플랜 배포 전



역할 분담

누가	무엇을
LLM	누적 문서 해석, 개방형 응답 코딩, 새 문항 문구, 플랜 문장(숫자는 인용만)
코드	결정 기여도, 효과 추정, 고객별 배정, 폐기·승격·되돌리기, 문장 검증
사람	설문 발송 승인, 액션플랜 배포 승인, 불변 규칙 변경

불변 영역 — 진화기가 못 건드림

- 추세 비교용 앵커 문항(전반 만족)
- 무작위 대조군 하한 10% (기본 15%)
- 숫자 검증기
- 고객 ID 가명 처리 · 개인정보 LLM 비전송

에이전트 코드가 시뮬레이션 정답 모듈을 import 하지 못하게 시험으로 막았다(tests/test_core.py).

OpenAI 스택(2026-11 기준)

구성	선택
오케스트레이션	Agents SDK 0.24.0 · Responses API · Structured Outputs
사람 승인	`needs_approval=True` (발송·배포 도구)
숫자 보증	출력 가드레일 = 검증기(하나라도 틀리면 차단)
평가	자체 하네스 — Agent Builder·호스티드 Evals 는 11-30 종료 예정이라 미사용

모델 배분 — 오류가 번지는가, 되돌릴 수 있는가

단계	모델	이유
개방형 1차 코딩	gpt-6-luna	대량·되돌릴 수 있음. 사람 코딩 200건과 κ 비교, 선행 연구 zero-shot κ 0.76 미달 시 상향
불일치 판정·문항·플랜 문장	gpt-6.1-sol	고객에게 나가거나 경영 판단에 쓰임
스캔본·표 이미지	gpt-6.1-terra	시각 입력
기여도·배정·폐기	코드	재현·감사 가능해야 함

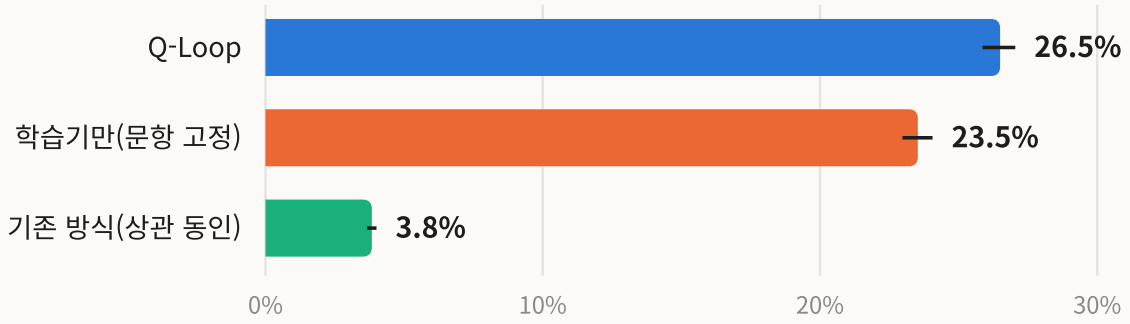
합성 응답자는 의사결정에 쓰지 않는다 — LLM 실리콘 샘플링이 응답을 동질화한다는 연구 결과(Li 외, arXiv 2507.02919) 때문.

실증 1 · 심은 정답 시뮬레이션 (사전등록)

문항이 진화하면 액션이 맞는 고객에게 간다

후지필름형 세그먼트 3개(파트너 400곳 · 산업재 160곳 · 회원 4,000명), 8분기, 시드 20개. 누적 문항이 재지 못하는 니즈(결품·납기·필름값)와 5분기에 새로 생기는 굿즈 수요를 심었다. 세 정책을 공통 난수로 같은 세계에 나란히 돌렸다.

8분기 누적 순이익 — 정답을 알 때의 최선 대비 포착률 (선: 시드 부트스트랩 95% 구간)



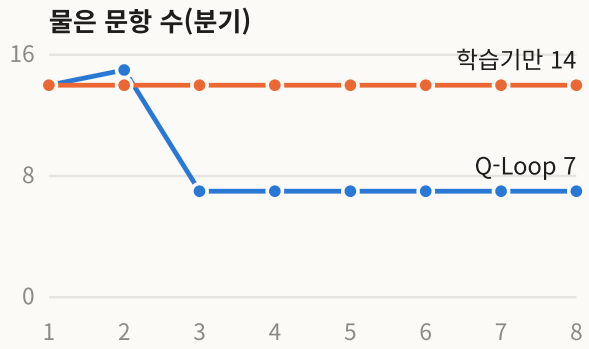
세그먼트	Q-Loop	학습기만	기존 방식
사진관·인화점 파트너	13.7%	8.1%	1.2%
산업재(LTO·프리스케일)	17.7%	16.1%	11.0%
인스탁스·몰 회원	27.4%	24.5%	3.8%

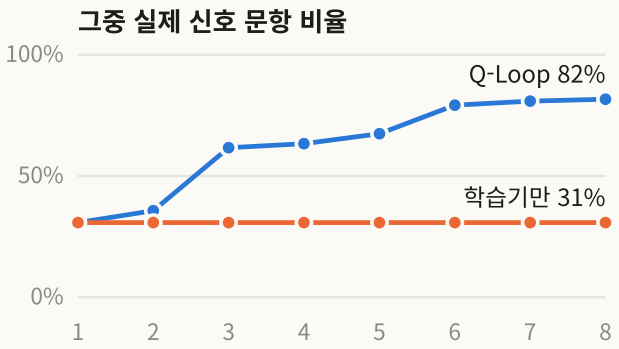
짝 차이 Q-Loop − 학습기만 +3.0%p [2.6, 3.3], 20/20 시드 우위. 응답률이 설문 길이에 안 떨어지는 세계에서도 +2.8%p — 우위가 짧은 설문의 응답률 효과만은 아니다.

진화 판단의 정오(세계 정답으로 채점)	승격 중 실제 신호	폐기 중 실제 신호
사진관·인화점 파트너	19/26	11/40
산업재(LTO·프리스케일)	8/14	24/80
인스탁스·몰 회원	38/40	2/17

B2C 처럼 응답이 많으면 승격이 정확하다. 고객이 적은 B2B 는 오폐기가 약 30% — 구축방안의 계층 모델 보완 대상.

B2C 회원 세그먼트 — 설문은 짧아지고 신호는 진해진다

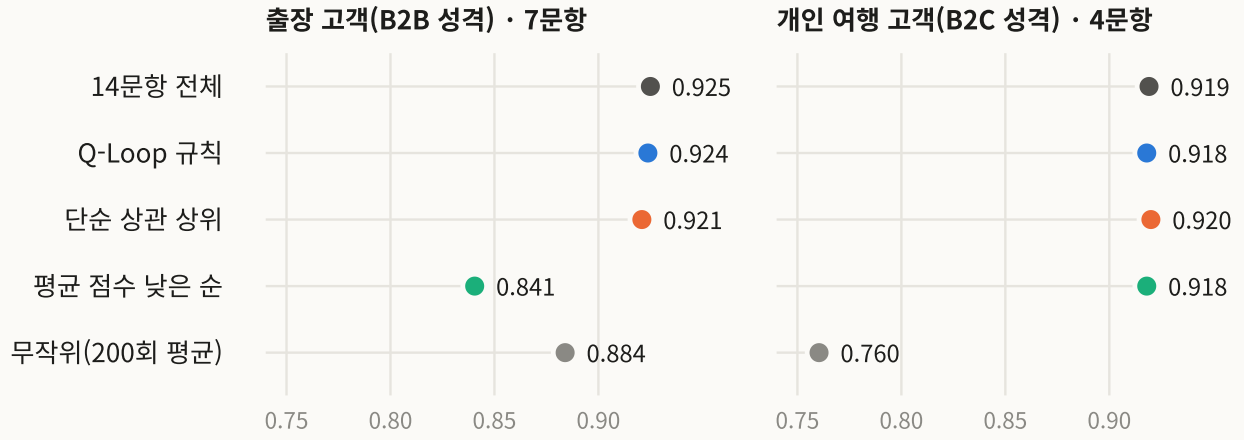




누적 문항이 못 재던 니즈는 모든 시드에서 2분기에 새 문항으로 잡혔고, 5분기에 생긴 굿즈 수요는 그다음 분기에 잡혔다. 되돌리기는 60개 세그먼트-실행 중 5회 발동. **한계:** 이 세계는 직접 만든 것이라 결과는 "메커니즘이 설계대로 작동한다"는 증거이지 실제 매출 효과의 크기가 아니다. 기존 방식의 낮은 성적은 '만족도가 매출 수준과만 엮인다'는 세계 가정에서 나온다.

실제 사람 응답에서도 정보를 잃지 않고 줄었다

공개 항공 만족도 설문(학습 103,904명 · 시험 25,976명, 서비스 평가 14문항 + 만족 여부)을 출장 고객(B2B 성격)과 개인 여행 고객(B2C 성격)으로 나눠, 응답을 6개 물결로 흘리며 같은 폐기 규칙을 적용했다. 시험 데이터는 마지막에 한 번만 썼다. 비교 방식에는 Q-Loop 가 스스로 정한 문항 수를 그대로 줬다.



세그먼트	Q-Loop 가 남긴 문항
출장 고객(B2B 성격)	온라인 탑승수속 · 탑승 서비스 · 체크인 서비스 · 기내 엔터테인먼트 · 기내 와이파이 · 다리 공간 · 게이트 위치
개인 여행 고객(B2C 성격)	기내 와이파이 · 온라인 예약 편의 · 게이트 위치 · 온라인 탑승수속

정직하게 읽기. 결과 예측만 보면 단순 상관 상위 선택도 비슷했다(출장 0.921, 개인 0.920). 개인 고객에서는 '평균 점수 낮은 순'도 같은 문항을 골랐다. Q-Loop 의 차별점은 예측이 아니라 **액션 효과를 가르는 데** 있고, 그건 실증 1이 보여 준다. 이 실험이 보여 주는 것은 폐기 규칙이 실제 응답에서 정보를 잃지 않는다는 점과, B2B·B2C 설문이 서로 다르게 줄어든다는 점이다.

검증기 — 틀린 숫자 문장은 배포되지 않는다

틀리게 바꾼 방식	차단/생성
숫자 크기 변경	389/389
부호 뒤집기	239/239
자릿수 바꾸기	390/390
근거 문항 바꿔치기	120/120
인용 없는 숫자 끼워 넣기	390/390
합계	**1528/1528**
맞는 문장 통과	390/390

규칙: ①인용한 값마다 표에서 다시 꺼내 같은 형식으로 쓴 문자열이 문장에 그대로 있어야 한다 ②문장 속 숫자는 전부 인용에서 나와야 한다 ③인용한 근거 문항 문구가 표와 같아야 한다.

문장 생성기와 검증기를 같은 사람이 만들었으므로 기계적 보증 시험이다. 본선에서 OpenAI 모델이 쓴 문장으로 차단율을 다시 잰다. Agents SDK 출력 가드레일로 연결해 키 없이 구성 시험을 통과했다 (qloop/agent_openai.py --build-only).

본선 계획

당일 공개 데이터로 1박 2일 안에 고리를 닫는다

시간	할 일	끝났다는 기준
0~2h	데이터 구조 파악, 입력 어댑터 3종(누적 설문 · 응답 · 매출) 매핑. 매출이 없으면 재구매·문의를 대리 결과로	표준 응답표·결과표가 가명 ID로 결합
2~6h	누적 자료 → 문항 은행 적재(계보·주제), 첫 회차 분석	문항별 결정 기여도 표
6~12h	액션플랜 + 검증 가드레일 + 승인 흐름 연결	틀린 숫자 문장 차단을 현장 데이터로 시연
12~18h	현장 과거 회차를 순서대로 다시 돌리는 백테스트로 진화 규칙 효과 측정	문항 수·포착률을 현장 데이터에서 실측
18~24h	담당자 화면(거래처 방문 리스트 · 캠페인 타깃 · 바뀌는 문항과 이유)과 발표	측정한 숫자만 발표

사전 작성 코드 사용 가능 여부는 미확인. 허용되면 저장소를 그대로, 불허면 설계·규칙·시험 케이스만 가져가 핵심부(분석·진화·검증)를 다시 구현한다.

성과 지표

- 설문 문항 수 · 응답률
- 무작위 대조군 대비 액션 순이익
- 개방형 코딩 κ(사람 표본 대비)
- 검증기 차단율 · 되돌리기 횟수

확산

구조는 '설문 + 매출'이 있는 어느 계열사에나 그대로 쓰인다. 어댑터만 바꾸면 칠성·웰푸드의 소비자 조사, 홈쇼핑의 방송 후 설문에도 붙는다. 롯데이노베이트 아이멤버의 에이전트로 넣으면 그룹 공통 도구가 된다.

알려진 약점 → 보완

- 작은 B2B 세그먼트는 검정력 부족(오폐기 약 30%) → 세그먼트 간 정보를 빌리는 계층 모델
- 액션 여러 개 중 최대 |t| 라 우연히 큰 값 → 순열 귀무분포로 임계값 보정
- 오프라인 코더는 시뮬 문장과 같은 손에서 나와 정확도가 과대평가 → 본선은 LLM 코딩 + 사람 표본 κ

예시 — 시드 0 회원 세그먼트의 진화 원장(실행 기록 그대로)

시점	변경	문항	근거
1분기	새 문항 후보	「필름 가격 때문에 촬영을 줄인 적이 있다」	개방형 응답에서 '필름가격' 가 14% — 이를 재는 문항이 없음
2분기	폐기	「후지필름몰 앱이 편리하다」	최근 2회 결정 기여도 |t|<1.0
2분기	폐기	「오프라인 매장을 자주 방문한다」	최근 2회 결정 기여도 |t|<1.0
3분기	승격	「필름 가격 때문에 촬영을 줄인 적이 있다」	새 문항 시험 통과 — 결정 기여도 연속 |t|≥2.0
5분기	새 문항 후보	「사진으로 포토카드·굿즈를 만들어 보고 싶다」	개방형 응답에서 '굿즈·포토카드' 가 12% — 이를 재는 문항이 없음
8분기	승격	「사진으로 포토카드·굿즈를 만들어 보고 싶다」	새 문항 시험 통과 — 결정 기여도 연속 |t|≥2.0

스스로 검증하고 고치며 도는 루프를 만들어 왔다

클라우드 서버(Ubuntu)에 Claude Code(헤드리스)와 OpenAI Codex CLI 를 함께 두고 cron·systemd 로 묶어, 사람이 매번 지시하지 않아도 도는 에이전트 루프를 설계·운영해 왔다. Q-Loop 의 규칙들은 이 경험에서 나왔다.

자율 연구 루프 2026.09~10 159라운드 무인 운영

시장 데이터에서 반복 가능한 규칙을 찾는 연구를 에이전트에 맡겼다. 매 라운드 프롬프트 앞에 불변 규칙 · 폐기된 가설 목록(부활 조건 필수) · 남은 산출물 목록을 붙여 기억에 기대지 않게 했고, 감사·실행·제안·탐색 네 모드로 나눠 새 방향 탐색만 사람 승인을 받게 했다. 사전등록과 홀드아웃 분리를 지켰다. 결론은 "검증된 규칙 0건" — 그럴듯한 결과를 지어내지 않는 루프가 Q-Loop '근거 2회 전에는 안 바꾼다'의 출발점이다.

일감 자동 수주 엔진 2026.08 독립 채점 에이전트 · 자기 정제

프리랜서 플랫폼 일감 탐지 → 자동화 가능 판정 → 산출물 선제작 → 쓰기 권한 없는 채점 에이전트의 검수 → 입찰 → 결과 추적 → 규칙 자기 정제. 정제기는 불변/가변 영역을 나누고, 같은 근거가 3번 반복돼야 바꾸며, 회차당 2개만 바꾸고, 모든 변경을 원장·스냅샷으로 되돌릴 수 있게 했다. 첫 실전 입찰 10명 중 9위 뒤 "입찰자는 먼저 연락할 수 없다"는 구조적 원인을 찾아 전략을 바꿨다.

사고 구조 복원 엔진 2026.09 비정형 → 의사결정 필드

공개 SNS 글을 수집해 '무엇을 보고 · 어떤 사건에 반응하고 · 무엇을 따지고 · 어떤 가설 · 무엇으로 확인하는가'로 구조화했다. 개방형 응답 코딩과 같은 문제다. 학습·검증 데이터를 물리적으로 분리해 검증 데이터를 한 모델이 아예 못 읽게 했다.

공공데이터 공모전 응모 파이프라인 2026.10~ 수집 · 문서 생성 · 블라인드 심사

공식 통계 API 수집기(키를 로그·출력에서 가림), HWP/HWPX 문서 생성과 렌더링 검수, 블라인드 AI 심사와 원출처 대조를 묶어 여러 대회 응모작을 만들었다.

일하는 원칙 — 실패에서 나온 것

측정과 판정을 분리한다 · 불확실한 응답을 성공으로 읽지 않는다 · 모든 상수에 도출 근거, 없으면 지운다 · 문서의 안전장치가 코드에 실제로 있는지 확인한다 · 합계가 맞아도 구간별로 다시 맞춘다.

이 응모작도 같은 방식으로 만들었다: 지원자가 목표와 검증 원칙(실측 숫자만 · 비교 전 사전등록 · 정답 모듈 격리)을 정하고, AI 에이전트가 과제 분석·구현·실험·문안 초안을 맡고, 지원자가 검토해 제출한다.